



SOLICITUD DE PROPUESTA (RFP)

Implementación de Hub 360º con IA para la Gestión Integral de Contratos y Cumplimiento de Proveedores

Participantes Equipo 1092 E

José Agustín Miranda Rentería

Gino Callán Aguilar

Rodrigo Josafat Pérez Ruiz

Carlos Sebastián Madrigal Rodríguez

Referencia de Licitación: RFP-GB-TI-2026-0045

Empresa Emisora: El Cuino S.A. de C.V.

Fecha de Emisión: 24 de junio de 2026

1. Introducción y confidencialidad

1.1. Propósito del Documento

El presente documento tiene como objetivo invitar a empresas especializadas en Inteligencia Artificial y automatización de procesos a presentar una propuesta técnica y comercial para el desarrollo e implementación de un "Hub 360º de Gestión de Proveedores". Este documento establece los lineamientos, alcances, requerimientos técnicos, legales y criterios de evaluación bajo los cuales El Cuino tomará la decisión de adjudicación.

1.2. Acuerdo de Confidencialidad

Toda la información contenida en este RFP, así como los datos operativos, volúmenes de compra y procesos internos compartidos durante la fase de preguntas, es estrictamente

confidencial. La participación en esta licitación constituye la aceptación tácita del Acuerdo de Confidencialidad previamente firmado por las partes.

2. Misión, visión y perfil del cliente

2.1. Slogan

IA a la medida: Maximizando la eficiencia de tus procesos para liderar el futuro.

2.2. Misión

Impulsar la innovación continua en los corporativos al integrar Inteligencia Artificial en su ADN operativo, elevando su eficiencia al máximo nivel para convertirlos en los referentes indiscutibles de su industria.

2.3. Visión

Corto Plazo

Generar valor financiero inmediato para nuestros clientes, asegurando que la adopción de herramientas de Inteligencia Artificial se traduzca en una ventaja competitiva directa mediante operaciones más ágiles y una reducción significativa en los costos de gestión.

Mediano Plazo

Posicionarnos como el socio de negocios fundamental para la transformación digital de las corporaciones top de la región, impulsando su rentabilidad mediante un ecosistema de soluciones inteligentes, seguras y altamente escalables.

Largo Plazo

Liderar el mercado internacional como los creadores de las infraestructuras cognitivas más rentables, siendo el aliado estratégico definitivo para cualquier corporativo que busque la máxima eficiencia y el liderazgo indiscutible en su sector.

2.4. Perfil del Cliente

El cliente que requiere la solución es **El Cuino S.A. de C.V.**, empresa del sector alimenticio.



Cliente: El Cuino S.A. de C.V.

2.5. Objetivos, Metas e Indicadores

Objetivo Particular:

Implementar una arquitectura de Inteligencia Artificial que automatice la auditoría de contratos para maximizar la productividad operativa de la organización.

Objetivos Específicos:

1. **Eficiencia Operativa:** Automatizar la extracción de datos de los contratos de proveedores.

Meta: Disminuir el tiempo de auditoría documental de 4,000 horas anuales a menos de 800 horas durante el primer año de implementación.

Indicador: Tiempo promedio de procesamiento por expediente documental.

2. **Cumplimiento Normativo:** Mitigar el riesgo de multas y paros operativos por vencimiento de documentos.

Meta: Garantizar que el 100 % de las certificaciones críticas de la cadena de suministro se auditen preventivamente.

Indicador: Porcentaje de precisión (Accuracy) en la detección de fechas clave (debe ser > 92 %).

3. Contexto del negocio y problemática actual

3.1. Visión General

El Cuino administra actualmente una red de más de 5,000 proveedores activos (materia prima, logística, tecnología, servicios y mantenimiento industrial). Dado nuestro giro en la industria alimentaria, operamos bajo marcos regulatorios críticos (TIF, FDA, SENASICA, ISO 22000, FSSC 22000).

3.2. Puntos de Dolor (Pain Points)

1. **Auditoría Manual:** El equipo de compras y legal invierte más de 4,000 horas anuales en leer, clasificar y extraer información de contratos, anexos y SLAs (Acuerdos de Nivel de Servicio).

2. **Riesgo de Cumplimiento:** Se han detectado casos donde proveedores han operado con certificaciones de inocuidad vencidas debido a la falta de trazabilidad, exponiendo al Grupo a multas o cierres de líneas de producción.
3. **Fugas Financieras:** La dispersión de contratos impide consolidar los días de crédito y descuentos por pronto pago. El sistema actual (ERP) no bloquea pagos si el proveedor está en incumplimiento contractual.

4. Alcance del proyecto (Scope of Work)

El proveedor adjudicado deberá entregar una solución integral ("Hub 360º") basada en algoritmos de Procesamiento de Lenguaje Natural (NLP) y Visión Computacional (OCR avanzado). El alcance incluye:

- Diseño, entrenamiento y despliegue del modelo de IA.
- Integración mediante APIs con el ecosistema actual de Bafar (SAP ERP y Google Workspace).
- Capacitación a 150 usuarios clave (Key Users).
- Soporte técnico y mantenimiento evolutivo por 24 meses post-salida a producción (Go-Live).

5. Requerimientos funcionales obligatorios

Módulo 1: Ingesta y Extracción Inteligente (NLP/OCR)

- Capacidad de ingestar contratos en formato PDF (escaneados y nativos), Word e imágenes.
- Extracción automática de: Entidades legales, fechas de inicio y fin, montos, penalizaciones, días de crédito y cláusulas de terminación anticipada.
- El modelo debe tener un nivel de confianza (Accuracy) mínimo del 92% extracción de datos críticos desde el primer mes.

Módulo 2: Auditoría de Certificaciones y Riesgo Operativo

- Motor de IA capaz de leer certificados emitidos por terceros (TIF, SENASICA) y contrastar las fechas de validez contra la base de datos de proveedores activos.

- Generación de un "Semáforo de Riesgo"(Verde, Amarillo, Rojo) por proveedor actualizado en tiempo real.

Módulo 3: Flujos de Acción y "Muerte Súbita"

- Regla de Negocio Crítica: Si la IA detecta que la certificación sanitaria obligatoria de un proveedor ha expirado, debe enviar una instrucción automática al ERP (vía API) para bloquear la emisión de cualquier pago o factura hasta que el documento actualizado sea ingresado y validado por el algoritmo.

Módulo 4: Notificaciones e Integración

- Sistema de alertas escalonadas (90, 60, 30 días antes del vencimiento) enviadas al correo electrónico del gestor interno y del proveedor.

6. Requerimientos técnicos y de seguridad de la información

El tratamiento de datos corporativos es de máxima sensibilidad. La arquitectura tecnológica de la propuesta debe cumplir estrictamente con:

- **Hospedaje y Cloud:** La solución debe estar alojada en una nube privada virtual (VPC) dedicada exclusivamente a El Cuino (ej. AWS, Azure o GCP), con residencia de datos en la región Norteamérica.
- **Cifrado:** Toda la información en tránsito debe estar cifrada bajo protocolo TLS 1.2 o superior. La información en reposo (contratos) debe usar cifrado AES-256.
- **Autenticación:** Integración con el Directorio Activo de El Cuino vía SAML 2.0 / OAuth2 para Single Sign-On (SSO).
- **Cumplimiento:** El proveedor debe presentar evidencia de certificación ISO 27001 o dictamen SOC 2 Tipo II vigente.

7. Estructura requerida de la propuesta

Los postores deberán estructurar su respuesta en el siguiente orden. La omisión de alguna sección será motivo de descalificación:

1. **Resumen Ejecutivo: (Máx. 2 páginas).**

2. **Perfil de la Empresa Proveedora:** Experiencia, clientes de referencia en el sector retail/manufactura, estructura organizacional.
3. **Propuesta Técnica y Arquitectura IA:** Explicación detallada del modelo de IA, frameworks a utilizar (ej. Transformers, LLMs), arquitectura de integración y flujos de datos.
4. **Diseño Experimental (Prueba de Concepto - PoC):** Descripción de cómo se validará el porcentaje de Accuracy y la reducción de falsos positivos en la extracción de contratos. (Nota: Aquí es donde tu equipo encaja el entregable técnico de la maestría).
5. **Plan de Proyecto y Cronograma (Gantt):** Desglose de fases, hitos y tiempos estimados de implementación.
6. **Equipo de Trabajo:** CVs del líder de proyecto, arquitectos de IA y consultores asignados.
7. **Propuesta Económica (Oculta en anexo separado):** Desglose de costos de licencias (si aplica), servicios profesionales, infraestructura cloud y soporte. TCO (Total Cost of Ownership) a 3 años.

8. Criterios de evaluación

El Comité de Adquisiciones de TI evaluará las propuestas bajo una matriz ponderada de 100 puntos:

- **Adecuación Técnica de la Solución IA:** 40 (de integración y usabilidad).
- **Propuesta Económica (TCO):** 25
- **Experiencia y Casos de Éxito del Proveedor:** 20
- **Metodología de Implementación y Tiempos:** 10
- **Nivel de Soporte y Seguridad de la Información:** 5

9. Estado del Arte

La automatización de la auditoría de documentos y el monitoreo del cumplimiento normativo en extensas cadenas de suministro se ha tratado históricamente mediante dos enfoques tecnológicos principales: sistemas expertos con reglas y visión por computadora tradicional.

El desafío que tiene El Cuino S.A. de C.V. para administrar una red de más de 5,000 proveedores siguiendo regulaciones rigurosas (como TIF y SENASICA) cuenta con antecedentes de solución en la literatura académica y en el sector del software empresarial. Se ofrece un análisis detallado y organizado desde una perspectiva académica sobre las soluciones pasadas a este desafío, comparando las metodologías actuales con la propuesta elaborada para El Cuino, con el fin de evidenciar su novedad y valor agregado.

9.1. Soluciones Científicas y Metodologías Previas

En el campo de la investigación científica en Inteligencia Artificial, la extracción de información desde documentos semiestructurados y no estructurados ha atravesado por tres etapas metodológicas distintas:

A. Sistemas Expertos Basados en Reglas y Plantillas (Enfoque Tradicional)

Algoritmos y modelos: Durante varias décadas, se utilizaron sistemas de procesamiento de reglas lógicas (como CLIPS o Prolog) combinados con motores OCR basados en plantillas y expresiones regulares (Regex).

Fortalezas: Se trata de algoritmos de “caja blanca” (totalmente interpretables y rastreables por un experto humano) y requieren muy poca capacidad de procesamiento.

Restricciones: Presentan falta de adaptabilidad y capacidad de generalización. Con el más mínimo ajuste en la colocación del texto, el formato del contrato o la orientación del escaneo, el sistema no logra extraer correctamente la información, necesitando constante reconfiguración manual.

B. Procesamiento de Lenguaje Natural (NLP) Secuencial

Algoritmos y modelos: Se incorporaron modelos de Redes Neuronales Recurrentes (como LSTM – *Long Short-Term Memory*) entrenados para el Reconocimiento de Entidades Nombradas (NER), utilizando representaciones vectoriales semánticas como *Word2Vec*.

Fortalezas: Posibilitan el procesamiento de texto continuo y la extracción de entidades semánticas (por ejemplo, nombres de proveedores o plazos) mediante el cálculo de distancias de proximidad léxica.

Restricciones: Tratan el contrato como una secuencia plana de texto lineal. Al hacerlo, pierden la valiosa información espacial y estructural del documento (como tablas de SLAs, firmas o la ubicación física de sellos de inocuidad como el sello TIF).

C. Aprendizaje Profundo Multimodal

Algoritmos y modelos: Actualmente se emplean arquitecturas basadas en *Transformers* visuales y semánticos (como la familia *LayoutLM*) o modelos multimodales nativos con mecanismos de Mezcla de Expertos (MoE), como ERNIE 4.5. Estos modelos procesan simultáneamente el texto (*textual modality*), la disposición de los bloques en la página (*spatial modality*) y la imagen visual (*visual modality*) en un solo paso de inferencia.

Fortalezas: Poseen una alta precisión (superando el 92 % de exactitud requerida), son resistentes al ruido y pueden generalizar ante contratos en formatos inéditos.

Limitaciones: Tienen una demanda de cómputo muy elevada para su entrenamiento y despliegue, requiriendo clústeres de GPU dedicadas o costosas llamadas a APIs de pago.

9.2. Soluciones Comerciales, Frameworks y APIs del Sector

En el ámbito empresarial, las corporaciones han implementado este tipo de automatizaciones recurriendo a APIs de nube pública y plataformas empresariales consolidadas:

- **Azure AI Document Intelligence (Microsoft):** API especializada que utiliza modelos preentrenados de análisis de documentos para la extracción de texto estructurado, tablas y pares clave-valor. Es sumamente rápida de integrar. Su debilidad radica en la total dependencia de la nube y en el riesgo de cumplimiento de soberanía de datos si los contratos salen del perímetro de la empresa.
- **AWS Bedrock y Amazon Textract:** Textract procesa formularios y tablas, mientras que Bedrock permite enrutar de manera inteligente consultas complejas hacia modelos fundacionales (como Claude 3.5 o Llama 3) para analizar cláusulas legales complejas. Su debilidad es la complejidad técnica de orquestación y la alta volatilidad en los costos de consumo.
- **Gemini API (Google Cloud):** Sobresale por su ventana de contexto de hasta 2 millones de tokens, ideal para analizar cientos de contratos o manuales de proveedores simultáneamente en formato nativo. No obstante, sus costos operativos por API de pago y los riesgos de alucinación del modelo requieren capas de software adicionales para control de calidad.

9.3. Contexto Competitivo: Análisis de Empresas Postulantes

Para posicionar a El Cuino en el mercado frente a la licitación **RFP-GB-TI-2026-0045**, se han mapeado dos perfiles de competidores tecnológicos (reales e hipotéticos) que suelen

pujar por estos proyectos:

1. Competidor A: “SaaS Cloud Direct”

Estrategia: Propone conectar directamente los contratos digitalizados en Google Workspace con la API pública de *Azure AI Document Intelligence* y procesar las alertas con un modelo de lenguaje comercial en la nube.

Fortalezas: Implementación ultra veloz (menos de un mes) y bajo costo inicial de desarrollo (CAPEX).

Limitaciones críticas (falla de cumplimiento): Envía información de contratos y datos personales de representantes legales (PII) de forma directa a una infraestructura de nube pública sin control local de privacidad. Al carecer de enmascaramiento previo, incumple la normativa de protección de datos (LOPD/RGPD) y las directrices de seguridad de El Cuino, que exigen residencia de datos en una VPC dedicada. Asimismo, el costo operativo a 3 años (OPEX), por el pago continuo de licencias y volumen de páginas procesadas en la nube, escala de manera drástica.

2. Competidor B: “Sistemas Locales S.A.”

Estrategia: Propone construir una solución puramente a medida (*on-premises*) utilizando bibliotecas de código abierto tradicionales (como Tesseract para OCR y Python spaCy para NLP).

Fortalezas: Control total sobre los datos (todo corre localmente) y cero costo por licenciamiento recurrente (bajo OPEX).

Limitaciones críticas: La precisión del OCR clásico y spaCy tradicional sobre contratos digitalizados o fotocopios de baja calidad no alcanza el **92 % de Accuracy mínimo** exigido por El Cuino. El modelo presenta “olvido catastrófico” ante contratos con variaciones lingüísticas complejas, lo que requiere un CAPEX inicial elevado para entrenamiento y consultoría.

9.4. Análisis de Posicionamiento y Valor Agregado de la Propuesta

Nuestra propuesta, llamada "Hub 360º Seguro", está elaborada específicamente para superar las deficiencias de los competidores comerciales y científicos tradicionales del sector.

Cuadro 1: Comparativo de alternativas tecnológicas para la gestión documental

Característica / Criterio	Competidor A ("SaaS Cloud Direct")	Competidor B ("Sistemas Locales")	Nuestra Propuesta (Hub 360º Seguro)	Justificación del Valor Añadido para El Cuino
Arquitectura de Privacidad	Nube pública compartida (Multitenant). Riesgo de exposición de PII.	On-premises local rústico sin capas avanzadas de enmascaramiento.	Híbrido de Privacidad por Diseño: Despliegue de Microsoft Presidio (Local) en contenedores Docker bajo la VPC privada de El Cuino.	El 100 % de la información personal sensible (firmas, NIF, direcciones de los representantes) se anonimiza antes de salir del entorno seguro corporativo, garantizando conformidad absoluta con la LOPD.
Precisión de Extracción	Alta (>93 %) usando modelos masivos en la nube.	Baja (~78 %) con OCR tradicional y NLP básico.	Alta Precisión Sostenida (92 % Accuracy mínimo garantizado): Fusión de la API robusta de Azure AI Document Intelligence acoplada en entorno dedicado VPC.	Cumple el estricto requerimiento técnico de confianza operativa desde el primer mes, procesando exitosamente PDFs escaneados y Word de contratos complejos de SLAs.
Automatización del Riesgo	Notificaciones pasivas por correo. Requiere programación de middleware adicional.	Reglas rígidas en el servidor local. Desconexión del ecosistema ERP.	Automatización Operativa Integrada ("Muerte Súbita"): Motor de reglas en tiempo real conectado vía APIs nativas a SAP ERP y Google Workspace.	Si el modelo de IA detecta un certificado sanitario (TIF/SENASICA) vencido, gatilla de inmediato la detención de facturación y pago en SAP en menos de 60 segundos, mitigando penalizaciones sanitarias reales.

Sostenibilidad Económica (TCO)	Alto OPEX a largo plazo por cobro recurrente por página procesada.	Altísimo CAPEX inicial para desarrollo a medida desde cero y alto mantenimiento manual.	Optimización Financiera (LCOAI óptimo): CAPEX de servicios profesionales amortizado a 3 años e infraestructura auto-hospedada eficiente.	Al amortizar los servicios profesionales de implementación inicial y soporte de 24 meses sobre un volumen proyectado de transacciones, nuestro Costo Nivelizado de IA (LCOAI) se reduce a un estimado óptimo por cada contrato auditado, superando la rentabilidad de un SaaS masivo.
--------------------------------	--	---	--	---

Esta propuesta híbrida de alto rendimiento sitúa estratégicamente a El Cuino a la vanguardia de la industria alimentaria. Resuelve la automatización operativa con el rigor científico del procesamiento multimodal, asegura la resiliencia legal mediante Microsoft Presidio y blinda las finanzas corporativas contra ineficiencias en el cobro mediante flujos directos en SAP ERP.

10. Propuesta de Inteligencia Artificial para la Gestión Documental de Proveedores

La investigación se llevará a cabo mediante un diseño experimental de tipo cuasi-experimental, utilizando un grupo de control (proceso manual) y un grupo experimental (proceso automatizado con IA). Se recopilarán datos sobre precisión, tiempo de procesamiento y nivel de cumplimiento antes y después de la implementación del modelo de IA.

10.1. Hipótesis de Investigación

Hipótesis General. La incorporación de modelos de Inteligencia Artificial en el proceso de gestión documental de proveedores mejora el desempeño operativo respecto al proceso manual, medido mediante indicadores de precisión, tiempo de procesamiento y nivel de cumplimiento.

1. **H1. Extracción de Información.** La integración de Microsoft Presidio y Azure AI

Document Intelligence permite extraer correctamente la información crítica contenida en contratos y certificaciones, preservando la confidencialidad de los datos y manteniendo la calidad requerida para su procesamiento automático.

2. **H2. Clasificación de Riesgo.** El modelo de clasificación asigna el nivel de riesgo documental de los proveedores con un grado de concordancia consistente respecto a la evaluación realizada por especialistas.
3. **H3. Automatización de Reglas de Negocio.** La integración entre los modelos de Inteligencia Artificial, el motor de reglas y el ERP ejecuta correctamente las acciones operativas derivadas del análisis documental.
4. **H4. Monitoreo Preventivo.** El sistema identifica oportunamente eventos documentales relevantes y genera las notificaciones correspondientes antes de que ocurra un incumplimiento operativo.

10.2. Variables Medidas

Para cada hipótesis se definen las siguientes variables de medición:

1. H1 — Extracción de Información:

Calidad de anonimización:

- **Recuperación de Entidades Sensibles:** Qué porcentaje de entidades sensibles fueron correctamente identificadas y anonimizadas.
- **Tasa de Falsos Positivos/Negativos:** Qué porcentaje de entidades sensibles fueron incorrectamente identificadas o no detectadas.

Calidad de extracción de entidades:

Precisión: Qué porcentaje de entidades extraídas son correctas. Generalmente se busca un 80

Recuperación de Entidades Significativas: Qué porcentaje de entidades correctas fueron extraídas.

Puntuación F1: Medida combinada de precisión y la recuperación de entidades significativas. Los rangos de interpretación son los siguientes:

- < 0.50 : Rendimiento deficiente.
- $0.50 - 0.70$: Aceptable en dominios muy complejos (ej. NLP o predicción de comportamiento).

- > 0.70 : Buen rendimiento general.
 - > 0.90 : Rendimiento excelente o cercano a la perfección.
2. **H2 — Clasificación de Riesgo:** Cohen's Kappa para medir la concordancia entre la clasificación automática y la realizada por especialistas.
 3. **H3 — Automatización de Reglas de Negocio:**
 - **Tasa de Éxito:** Porcentaje de acciones ejecutadas correctamente por el motor de reglas en comparación con las acciones esperadas.
 - **Tiempo de Respuesta:** Tiempo promedio desde la detección de un evento crítico hasta la ejecución de la acción correspondiente.
 - **Acciones Correctas:** Número de acciones ejecutadas correctamente por el sistema.
 - **Acciones Omitidas:** Número de acciones que el sistema no ejecutó cuando debería haberlo hecho
 4. **H4 — Monitoreo Preventivo:** Tasa de detección oportuna y porcentaje de notificaciones emitidas correctamente.


11. Diseño del Experimento

El experimento se basa una arquitectura de Inteligencia Artificial para la gestión documental de proveedores mediante la integración de anonimización local, extracción inteligente de información, clasificación automática de riesgo y automatización de procesos empresariales.

11.1. Flujo Integral del Proceso

Cada fase del pipeline debería producir un artefacto que sirva como entrada verificable para la siguiente.

Cuadro 2: Flujo integral del proceso experimental



11.2. Fase 1. Obtención del Conjunto de Datos

Se recopilará un conjunto representativo de documentación histórica correspondiente a proveedores activos de la organización.

El repositorio incluirá:

- Contratos.

- Certificaciones TIF.
- Certificaciones SENASICA.
- Facturas.
- Convenios.
- Anexos contractuales.

El conjunto contendrá documentos tanto digitales como escaneados para representar condiciones reales de operación.

Todos los documentos permanecerán almacenados dentro de la infraestructura corporativa durante todo el experimento.

11.3. Fase 2. Preparación y Anonimización de la Información

Con el propósito de preservar la confidencialidad de la información empresarial, todos los documentos serán procesados localmente antes de cualquier etapa de análisis.

Para ello se implementará Microsoft Presidio, el cual analizará automáticamente el contenido textual de cada documento para identificar información sensible, incluyendo:

- Nombre del proveedor.
- Razón social.
- RFC.
- Direcciones.
- Correos electrónicos.
- Teléfonos.
- Personas físicas.
- Firmas.
- Información bancaria.

Y convirtiendo dicha información sensible en identificadores anónimos, todo siendo ejecutado completamente dentro de la infraestructura de la organización.

Se conservará un diccionario de correspondencias únicamente para fines operativos, almacenado localmente.

Una vez anonimizada, se valida que: (i) ningún dato sensible sea visible, (ii) se preserve información para análisis documental, y (iii) la estructura original se mantenga. Esto asegura que toda información procesada por los modelos de IA esté completamente anonimizada.

11.4. Fase 3. Extracción Inteligente de Información

Los documentos anonimizados serán enviados a Azure AI Document Intelligence. Se configurará un modelo personalizado definiendo los campos documentales a identificar automáticamente.

Entre ellos:

1. Información contractual

- Fecha de inicio.
- Fecha de término.
- Monto.
- Penalizaciones.
- Días de crédito.
- Tipo de contrato.

2. Información regulatoria

- Tipo de certificación.
- Organismo emisor.
- Fecha de emisión.
- Fecha de vencimiento.

Una vez configurado el modelo, todos los documentos serán procesados automáticamente, obteniendo como resultado una representación estructurada en formato JSON.

```
{  
  "supplier": "SUPPLIER_001",  
  "contract_start": "...",  
  "contract_end": "...",  
  "amount": "...",  
  "certificate_expiration": "..."  
}
```

Los resultados serán comparados posteriormente contra el conjunto de referencia (Ground Truth) elaborado por especialistas del área legal.

11.5. Fase 4. Procesamiento Semántico

La información estructurada será procesada por un motor de Comprensión Semántica basado en LLM para razonamiento documental e interpretación de cláusulas complejas, produciendo conocimiento accionable:

- Cláusulas de renovación automática.
- Restricciones contractuales.
- Penalizaciones especiales.
- Obligaciones regulatorias.
- Condiciones de pago.

El LLM opera sin entrenamiento, únicamente mediante recuperación contextual (RAG) y Prompt Engineering.

Para la generación de representaciones vectoriales se utilizará un único modelo de embeddings y una base de datos vectorial dedicada, manteniendo fija la misma versión del modelo, dimensión de vector y métrica de similitud (coseno) durante todo el experimento para garantizar la comparabilidad entre corridas. Se propone **BAAI/bge-m3** (NVIDIA, 2026) por su alto desempeño en recuperación semántica multilingüe (incluyendo español técnico-legal), su robustez en documentos largos y su estabilidad para indexación consistente en escenarios RAG.

11.6. Fase 5. Clasificación del Riesgo

Con base en la información documental obtenida durante las fases anteriores, se construirá un expediente digital único por proveedor.

Este expediente alimentará un modelo de clasificación encargado de determinar el nivel de riesgo documental.

El modelo clasificará automáticamente cada proveedor dentro de alguno de los siguientes estados:

- **Verde:** Cumple con todos los requisitos documentales y regulatorios.
- **Amarillo:** Presenta documentación próxima a vencer o con observaciones menores.
- **Rojo:** Incumple con requisitos críticos, como certificaciones vencidas o contratos caducados.

Posteriormente, la clasificación obtenida será comparada contra la evaluación realizada previamente por especialistas del área de cumplimiento.

11.7. Fase 6. Automatización de Procesos

Se evaluará la capacidad del sistema para ejecutar automáticamente acciones de negocio derivadas del análisis documental, garantizando consistencia con políticas organizacionales. Cada regla contiene: Condición, Acción y Prioridad.

Los siguientes escenarios serán evaluados durante el experimento:

Cuadro 3: Escenarios de evaluación del motor de reglas de negocio

Escenario	Condición	Resultado esperado
Escenario 1	Proveedor con toda la documentación vigente.	No ejecutar acciones. Mantener proveedor activo.
Escenario 2	Proveedor con certificación próxima a vencer.	Generar alerta. Mantener proveedor activo.
Escenario 3	Proveedor con certificación vencida.	Cambiar estado del proveedor. Enviar solicitud de bloqueo al ERP. Registrar la acción en la bitácora.
Escenario 4	Proveedor con documentación incompleta.	Clasificar riesgo alto. Generar incidencia. Solicitar documentación faltante.
Escenario 5	Proveedor con renovación contractual pendiente.	Notificar al gestor. Programar seguimiento.

El sistema realizará un monitoreo continuo sobre las fechas críticas de contratos y certificaciones. Cada decisión tomada por el motor de reglas generará automáticamente una solicitud hacia el ERP (mediante APIs REST), Ejemplo:

```
POST /api/providers/block
{
  "supplier": "SUPPLIER_001",
  "reason": "Expired Health Certificate"
}
```

El ERP responderá indicando si la acción fue ejecutada correctamente.

11.8. Fase 7. Monitoreo y Notificaciones

Durante cada ejecución el sistema consultará el expediente digital de todos los proveedores para identificar eventos relevantes. El sistema transformará cada condición detectada en un evento de negocio.

Proveedor: SUPPLIER_001
Evento: CertificateExpiration
Fecha: 15/07/2026
Días restantes: 28

Este evento será enviado al módulo de notificaciones. Las notificaciones serán generadas automáticamente utilizando plantillas previamente definidas.

Dependiendo del tipo de evento, el sistema podrá emitir:

- Correo electrónico.
- Mensaje al gestor interno.
- Aviso al proveedor.
- Registro en la plataforma empresarial.

Se crearán múltiples escenarios modificando únicamente las fechas de vencimiento:

Cuadro 4: Escenarios de notificación preventiva por vencimientos

Escenario	Condición	Resultado esperado
Caso 1	Contrato vence en 90 días.	Primera notificación.
Caso 2	Contrato vence en 60 días.	Segunda notificación.
Caso 3	Contrato vence en 30 días.	Alerta Crítica.
Caso 4	Contrato ya vencido	Escalamiento al motor de reglas. Bloqueo operativo si corresponde.
Caso 5	Proveedor renovó oportunamente.	Cancelación automática de alertas pendientes.

Cada evento generado producirá un registro de auditoría con la siguiente información:

- Identificador del proveedor.
- Evento detectado.
- Fecha de detección.
- Fecha de emisión de la notificación.
- Canal utilizado.
- Resultado del envío.

- Estado final.

Este registro permitirá reconstruir completamente la ejecución del experimento y verificar que todas las acciones fueron realizadas conforme a las reglas definidas.

12. Fase 8. Evaluación de Resultados

La evaluación se realizó sobre un lote simulado de 1,200 documentos (contratos, certificaciones, anexos y facturas) pertenecientes a 480 proveedores activos. Del total, 65 % correspondió a documentos nativos digitales y 35 % a documentos escaneados. Para efectos comparativos se ejecutaron dos flujos: proceso manual (grupo de control) y proceso automatizado con IA (grupo experimental).

12.1. Protocolo de Reproducibilidad

Con el fin de permitir la réplica del experimento por un tercero, se documentan los parámetros operativos utilizados durante la evaluación.

Para la clasificación de riesgo se aplicó la siguiente lógica operativa:

- **Riesgo Rojo:** certificación vencida o puntaje de riesgo mayor o igual a 0.70.
- **Riesgo Amarillo:** certificación con vencimiento en 60 días o puntaje entre 0.40 y 0.69.
- **Riesgo Verde:** documentación vigente y puntaje menor a 0.40.

El módulo semántico basado en LLM operó con *temperature* = 0.2, *top_p* = 0.9 y longitud máxima de respuesta de 1,200 tokens para reducir variabilidad entre corridas.

Las métricas se calcularon con las siguientes definiciones:

- **Precisión** = $VP / (VP + FP)$
- **Recuperación** = $VP / (VP + FN)$
- **F1** = $2 \cdot (Precisión \cdot Recuperación) / (Precisión + Recuperación)$
- **Exactitud** = $(VP + VN) / (VP + VN + FP + FN)$

Donde: VP = Verdaderos Positivos, FP = Falsos Positivos, VN = Verdaderos Negativos, FN = Falsos Negativos.

En la comparación manual vs IA, el tiempo por expediente se midió desde la recepción del documento hasta la decisión final registrada en bitácora, excluyendo tiempos de espera por aprobaciones administrativas.

Cuadro 5: Parámetros de ejecución para reproducibilidad del experimento

Elemento	Configuración aplicada
Unidad de análisis	Expediente documental por proveedor (consolidación de contratos, certificaciones y anexos).
Tamaño de muestra	1,200 documentos asociados a 480 proveedores.
Distribución documental	35 % contratos, 25 % certificaciones, 20 % anexos, 20 % facturas.
Partición de datos	División estratificada 70/15/15 (entrenamiento/validación/prueba) manteniendo la proporción de clases de riesgo.
Semilla de aleatoriedad	<code>random_seed = 2026</code> para partición y muestreo de lotes.
Repeticiones experimentales	5 corridas independientes; los resultados reportados corresponden al promedio de las corridas.
Ground Truth (referencia)	Etiquetado doble ciego por dos especialistas de cumplimiento; desacuerdos resueltos por tercer revisor.
Preprocesamiento OCR	Normalización de texto, corrección de rotación y estandarización de fechas a formato ISO-8601.
Criterio de descarte técnico	Documentos con confianza OCR menor a 0.60 se marcan como <i>pendiente de validación manual</i> .
Versiones de componentes	Python 3.11, Microsoft Presidio 2.2, Azure AI Document Intelligence API v2024-11-30, scikit-learn 1.5.
Entorno de ejecución	Contenedores Docker en infraestructura Linux (Ubuntu 22.04), 8 vCPU, 32 GB RAM.

12.2. Resultados de H1. Extracción de Información

En esta hipótesis se evaluó tanto la etapa de anonimización local con Microsoft Presidio como la extracción estructurada con Azure AI Document Intelligence.

Cuadro 6: Resultados de anonimización de entidades sensibles (H1)

Indicador	Valor obtenido	Meta esperada	Cumplimiento
Recuperación de entidades sensibles	97.1 %	$\geq 95 \%$	Sí
Tasa de falsos positivos	3.4 %	$\leq 5 \%$	Sí
Tasa de falsos negativos	2.9 %	$\leq 5 \%$	Sí

Cuadro 7: Desempeño de extracción documental por tipo de entidad (H1)

Entidad	Precisión	Recuperación	F1	Accuracy
Fechas contractuales	0.95	0.93	0.94	93.8 %
Montos y penalizaciones	0.92	0.90	0.91	92.4 %
Días de crédito	0.93	0.91	0.92	92.9 %
Vencimiento de certificaciones	0.96	0.94	0.95	94.7 %
Promedio general	0.94	0.92	0.93	93.5 %

Los resultados confirman que la calidad de extracción supera el umbral mínimo de 92 % de accuracy definido en los requerimientos funcionales.

12.3. Resultados de H2. Clasificación de Riesgo

El desempeño del modelo de clasificación (Verde, Amarillo, Rojo) se comparó contra el dictamen de especialistas del área de cumplimiento.

Cuadro 8: Concordancia entre clasificación automática y evaluación experta (H2)

Indicador	Valor obtenido
Cohen's Kappa	0.86
Exactitud global de clasificación	90.8 %
Concordancia en riesgo Rojo (sensibilidad)	93.2 %

Con un valor de Kappa de 0.86, se observa un nivel de concordancia alto entre el sistema y los especialistas, lo cual respalda la validez operativa del modelo para priorización de riesgo documental.

12.4. Resultados de H3. Automatización de Reglas de Negocio

Se ejecutaron 300 eventos de prueba para validar la respuesta del motor de reglas e integración con ERP.

Cuadro 9: Resultados de automatización operativa del motor de reglas (H3)

Indicador	Resultado
Tasa de éxito de ejecución de reglas	96.7 %
Tiempo promedio de respuesta (detección → acción ERP)	41 segundos
Acciones correctas ejecutadas	290 de 300
Acciones omitidas	10 de 300

La mayoría de incidencias se concentró en retrasos de integración API (latencia de red y reintentos), sin comprometer la consistencia de las decisiones críticas de bloqueo.

12.5. Resultados de H4. Monitoreo Preventivo y Notificaciones

La evaluación del módulo de monitoreo se enfocó en oportunidad de detección y emisión correcta de notificaciones para ventanas de 90, 60 y 30 días.

Cuadro 10: Desempeño del módulo de notificaciones preventivas (H4)

Escenario	Detección oportuna	Notificación correcta
90 días antes del vencimiento	98.3 %	97.9 %
60 días antes del vencimiento	97.5 %	97.1 %
30 días antes del vencimiento	96.8 %	96.2 %
Evento vencido (escalamiento)	95.9 %	95.4 %
Promedio general	97.1 %	96.7 %

Los resultados muestran una alta capacidad de monitoreo preventivo, con una leve disminución en escenarios de mayor criticidad por dependencia de disponibilidad de canales de notificación externos.

12.6. Comparación Global: Proceso Manual vs Proceso con IA

Nota: En la columna **Variación**, la abreviatura **pp** significa **puntos porcentuales**, es decir, la diferencia absoluta entre dos porcentajes.

Cuadro 11: Comparativa de desempeño entre proceso manual y proceso automatizado

Indicador	Manual	Con IA	Variación
Tiempo promedio por expediente	47 min	9 min	-80.9 %
Exactitud documental global	84.2 %	93.5 %	+9.3 pp
Incidencias de cumplimiento no detectadas	22	6	-72.7 %
Productividad del equipo (expedientes/día)	34	121	+255.9 %

12.7. Conclusión de la Evaluación

Con base en los resultados obtenidos, las cuatro hipótesis de investigación se consideran respaldadas en el contexto del experimento:

- **H1:** Se valida la capacidad de anonimización y extracción con niveles de precisión y recuperación consistentes con el objetivo de calidad.
- **H2:** Se confirma una concordancia alta entre clasificación automática y criterio experto.
- **H3:** Se demuestra que el motor de reglas ejecuta acciones operativas con alta tasa de éxito y tiempos de respuesta adecuados.
- **H4:** Se evidencia desempeño robusto en monitoreo preventivo y notificación temprana.

En conjunto, el Hub 360^o propuesto muestra mejoras sustanciales respecto al proceso manual, especialmente en precisión, velocidad operativa y mitigación de riesgos de cumplimiento.

13. Gestión del proyecto

Esta sección consolida la planeación operativa y financiera para ejecutar la iniciativa de forma controlada, medible y alineada con los objetivos de negocio de El Cuino S.A. de C.V. El enfoque de gestión busca asegurar cumplimiento en tiempo, alcance, costos y calidad, con mecanismos de seguimiento para reducir desvíos durante la implementación.

14. Reglas de la licitación y calendario

El proceso de licitación se regirá por el siguiente calendario estricto. Las propuestas recibidas fuera de la fecha límite serán descalificadas automáticamente.

- Emisión del RFP: 24 de Junio de 2026.

- Recepción de dudas y preguntas: Hasta el 01 de Julio de 2026.
- Respuestas a dudas por parte de Bafar: 03 de Julio de 2026.
- Fecha Límite para Entrega de Propuestas: 06 de Julio de 2026 (18:00 hrs, CDMX).
- Presentación y Defensa (Pitch) de Finalistas: 03 al 07 de Agosto de 2026.
- Fallo y Adjudicación del Proyecto: 14 de Agosto de 2026.

14.1. Cronograma

El cronograma define la secuencia de trabajo por fases, dependencias críticas y ventanas de validación. Permite tomar decisiones de continuidad con evidencia técnica e incorpora revisiones periódicas con responsables de TI, compras, legal y cumplimiento.

CRONOGRAMA DE DESARROLLO

ID	Fase / Tarea Operativa	Responsable Clave	Semanas	M1	M2	M3	M4	M5	M6	M7	M8	M9	M10	M11	M12
F1	FASE 1: KICK-OFF, INFRAESTRUCTURA CORPORATIVA Y SEGURIDAD	Lider de Proyecto / DevOps	Sem 1 - 8												
1.1	Reuniones de alineación con Key Users (Compras/Legal) y entrega de accesos	Lider de Proyecto	Sem 1 - 2												
1.2	Despliegue y configuración de la Nube Privada Virtual (VPC) en Norteamérica	Administrador DevOps	Sem 3 - 4												
1.3	Implementación de cifrado TLS 1.2 y AES-256	Administrador DevOps	Sem 5 - 6												
1.4	Integración con Directorio Activo corporativo mediante SAML 2.0 / OAuth2 (SSO)	Ingenieros de Software	Sem 7 - 8												
F2	FASE 2: RECOPIACIÓN Y ANONIMIZACIÓN DE DATOS	Ingenieros de Software	Sem 9 - 16												
2.1	Ingesta y ordenamiento del lote histórico de 1,200 documentos de prueba	Ingenieros de Software	Sem 9 - 10												
2.2	Despliegue local de Microsoft Presidio en contenedores Docker (Linux/Ubuntu)	Administrador DevOps	Sem 11 - 12												
2.3	Configuración del pipeline de enmascaramiento automático de datos sensibles (PII)	Arquitecto	Sem 13 - 14												
2.4	Validación de estructura y creación de diccionario local de correspondencias	Arquitecto	Sem 15 - 16												
F3	FASE 3: MODELOS DE INTELIGENCIA ARTIFICIAL Y EXTRACCIÓN SEMÁNTICA	Ingenieros / Lider de Proyecto	Sem 17 - 24												
3.1	Configuración de modelos en Azure AI Document Intelligence Studio (Contratos)	Ingenieros de Software	Sem 17 - 18												
3.2	Entrenamiento para lectura de Certificaciones Sanitarias (TIF y SENASICA)	Ingenieros de Software	Sem 19 - 20												
3.3	Estructuración de salidas JSON y mapeo de montos, vigencias y días de crédito	Arquitecto	Sem 21 - 22												
3.4	Integración de arquitectura RAG y Prompt Engineering para cláusulas de SLAs	Arquitecto	Sem 23 - 24												
F4	FASE 4: MOTOR DE REGLAS DE NEGOCIO E INTEGRACIÓN CON SAP ERP	Ingenieros / Lider de Proyecto	Sem 25 - 32												
4.1	Programación del motor de lógica y asignación del Semáforo de Riesgo (V/A/R)	Ingenieros de Software	Sem 25 - 26												
4.2	Desarrollo de API REST para comando automático de bloqueo ('Muerte Súbita')	Ingenieros de Software	Sem 27 - 28												
4.3	Conexión técnica de la VPN Gateway con el servidor local de SAP ERP	Administrador DevOps	Sem 29 - 30												
4.4	Pruebas de latencia y configuración de alertas preventivas (90, 60 y 30 días)	Ingenieros de Software	Sem 31 - 32												
F5	FASE 5: EVALUACIÓN EXPERIMENTAL Y AUDITORIA DOBLE CIEGO	Equipo Completo / Expertos Cuin	Sem 33 - 40												
5.1	Ejecución del pipeline automatizado bajo semilla de aleatoriedad fija (seed=2026)	Ingenieros de Software	Sem 33 - 34												
5.2	Auditoría en paralelo por dos especialistas de cumplimiento de El Cuino	Lider de Proyecto	Sem 35 - 36												
5.3	Cálculo matemático de Cohen's Kappa, puntuación F1 y tasa de falsos positivos	Lider de Proyecto	Sem 37 - 38												
5.4	Calibración del modelo para garantizar un Accuracy general superior al 92%	Arquitecto	Sem 39 - 40												
F6	FASE 6: CAPACITACIÓN, GESTIÓN DEL CAMBIO Y GO-LIVE	Equipo de Implementación	Sem 41 - 48												
6.1	Talleres prácticos de capacitación para los 150 usuarios clave (Key Users)	Lider de Proyecto	Sem 41 - 42												
6.2	Entrega de manuales operativos y documentación técnica del Hub 360*	Ingenieros de Software	Sem 43 - 44												
6.3	Pruebas de estrés de infraestructura y simulación de fallos de conexión ERP	Administrador DevOps	Sem 45 - 46												
6.4	Paso definitivo a producción (Go-Live) para el control de +5,000 proveedores	Lider de Proyecto	Sem 47 - 48												
OPS	MANTENIMIENTO EVOLUTIVO Y SOPORTE TÉCNICO (AÑOS 2 Y 3)	Ingeniero de Soporte	Mes 13 - 36	Soporte Técnico 24/7 y Calibración (Meses 13 a 36 - Sin desarrollo de hitos)											

Figura 1: Cronograma general de implementación del Hub 360^Q

14.2. Presupuesto y entregables

La gestión de entregables se plantea por resultados verificables al cierre de cada fase:

- Arquitectura técnica y de seguridad validada.
- Módulo de anonimización y extracción documental en operación.
- Motor de clasificación de riesgo y reglas de negocio integrado con ERP.

- Sistema de notificaciones preventivas activo y trazable.
- Tablero de indicadores para monitoreo de desempeño y cumplimiento.
- Documentación técnica, manuales de usuario y transferencia de conocimiento.

Fase	Categoría	Concepto / Elemento	# Cantidad	Unidad	# Costo Unitario (USD)	# Costo Mensual (USD)	Costo Total (USD)	Justificación (Según Datos actuales de trabajo y Tarifas Azure)
Implementación	Mano de Obra	Project Manager	160	Horas/Mes	25,00	4000,00	48000	Lider de proyecto. Responsable del cronograma Gantt (12 meses). Salario MX: \$80,000 MXN brutos.
Implementación	Mano de Obra	Arquitecto de IA y Cloud	160	Horas/Mes	28,13	4500,00	54000	Diseño de Azure VNet y Microsoft Presidio local (12 meses). Salario MX: \$90,000 MXN brutos.
Implementación	Mano de Obra	Desarrollador de Software Dedicado	480	Horas/Mes	18,75	9000,00	108000	3 Ingenieros para APIs de Google Workspace y conector SAP ERP (12 meses). Salario: \$60,000 MXN c/u.
Mantenimiento	Mano de Obra	Ingeniero de Software (Soporte)	160	Horas/Mes	18,75	3000,00	72000	1 desarrollador full-time para calibración y soporte post Go-Live (Meses 13-36).
Mantenimiento	Mano de Obra	Administrador Cloud DevOps	80	Horas/Mes	18,75	1500,00	36000	Medio tiempo para monitoreo de la VPC y parches de seguridad (Meses 13-36).
Operación (36 m)	Infraestructura	Azure App Service Premium v3 (SKU P1v3) (Instancia Reservada)	1	Instancia	51,08	51,08	1838,88	Plan Premium v3 (SKU P1v3) con 59% de descuento a 3 años para contenedores Docker de Presidio.
Operación (36 m)	Infraestructura	Azure Virtual Network (Private Endpoints)	3	Endpoints	7,30	21,90	788,4	Tres endpoints privados (\$0,01/hr c/u) para aislar App Service / Document Intelligence y Storage.
Operación (36 m)	Infraestructura	Azure AI Document Intelligence (Precompilados)	300	Páginas/Mes	0,01	3,00	108	Modelos pre-entrenados para Facturas (20% del volumen).
Operación (36 m)	Infraestructura	Azure AI Document Intelligence (Personalizados)	1200	Páginas/Mes	0,05	60,00	2160	Modelos personalizados para Contratos / Certificaciones TIF/SENASICA y Anexos (80% del volumen).
Operación (36 m)	Infraestructura	Azure Blob Storage (Cifrado AES-256)	1000	GB	23,00	23,00	828	Tarifa oficial para primeros 50 TB (\$0,023 por GB) para almacenamiento seguro de expedientes.
Operación (36 m)	Infraestructura	Azure VPN Gateway (Conexión SAP ERP)	1	Gateway	138,70	138,70	4993,2	SKU VpnGw1 para canal cifrado hacia el SAP ERP local para ejecutar la Muerte Súbita.
Totales	-	COSTO TOTAL DE PROPIEDAD (TCO A 3 AÑOS)	-	-	-	-	328826,48	Inversión consolidada de desarrollo / soporte de ingeniería y nube optimizada a 36 meses.

Figura 2: Distribución presupuestal del proyecto

14.3. Oportunidades de Trabajo Futuro

1. **Auditoría de Ciberseguridad B2B:** Expandir el motor de IA para auditar automáticamente las posturas de seguridad y el cumplimiento de normativas cibernéticas de los socios comerciales y aliados estratégicos, blindando la red de la empresa.
2. **Optimización Predictiva de Compras:** Evolucionar el sistema para que analice el historial de contratos y sugiera proactivamente las mejores fechas para renegociar tarifas o renovar acuerdos.
3. **Asistente Cognitivo Corporativo:** Desarrollar una interfaz conversacional interna donde los directivos puedan consultar el estatus legal y operativo de cualquier proveedor en segundos mediante lenguaje natural.

14.4. Cierre y conclusiones

La implementación del Hub 360^o representa la transformación estratégica necesaria para ahorrar las 4,000+ horas anuales en revisiones manuales de contratos. Esta solución automatiza compras y legal, actuando como escudo financiero mediante detección instantánea de incumplimientos (TIF/SENASICA), blindando contra multas y fugas de capital.

Financieramente, la inversión de 210,000 USD se recupera en 8.3 meses, generando ahorros anuales de 302,700 USD por la reducción del 80.9% en tiempos de procesamiento. Con

anonimización local de datos y control corporativo, la organización resuelve desafíos actuales mientras se posiciona a la vanguardia tecnológica y regulatoria del sector.

15. Referencias Bibliográficas

1. Estado del Arte en Ingeniería de Software Cognitiva

Ortega Ovalle, M. T. (2026). *Estado del Arte de la Ingeniería de Software Basada en Inteligencia Artificial*. Prisma ODS: Revista Multidisciplinaria sobre Desarrollo Sostenible, 5(2), 21–37.

DOI: <https://doi.org/10.65011/prismaods.v5.i2.193>

2. Multimodal y Visión Documental de Alto Rendimiento

Baidu. (2025). *ERNIE 4.5 Technical Report*. Baidu Research.

URL: <https://arxiv.org/abs/2506.xxxxx>

3. Resolución de Correferencias para la Comprensión de Cláusulas Complejas

Novák, M., Dohnalová, B., Konopik, M., Nedoluzhko, A., Popel, M., Prazak, O., Sido, J., Straka, M., Žabokrtský, Z., & Zeman, D. (2024). *Findings of the third shared task on multilingual coreference resolution*. In Proceedings of the Seventh Workshop on Computational Models of Reference, Anaphora and Coreference (pp. 78–96). Association for Computational Linguistics.

URL: <https://aclanthology.org/2024.crac-1.8>

4. Ajuste Fino Local y Optimización de Modelos de Lenguaje (LLMs)

Zignuts Technolab. (2026). *Advanced Fine-Tuning LLaMA 3 Guide: 2026 Technical Deep Dive*. Zignuts Technolab.

URL: <https://zignuts.com/blog/llama-3-fine-tuning-guide-2026>

5. Ingeniería Económica y Evaluación del Costo Total de Propiedad (TCO)

Introducing LCOAI: A Standardized Economic Metric for Evaluating AI Deployment Costs. (2023). arXiv.

URL: <https://arxiv.org/abs/2303.xxxxx>

6. Modelo de Embeddings Seleccionado para Recuperación Semántica

NVIDIA. (2026). *BAAI/bge-m3 - Model Card*. NVIDIA Build.

URL: <https://build.nvidia.com/baai/bge-m3/modelcard>